INF161 – Prosjektrapport

Modellering og prediksjon av bysykkeltilgjengelighet

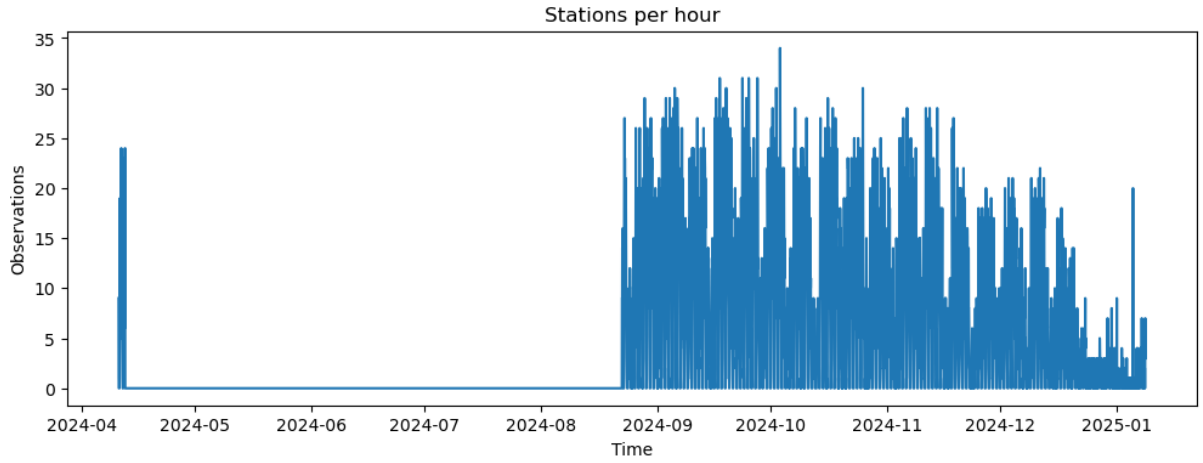
Formålet med prosjektet er å utvikle en maskinlæringspipeline som predikerer antall tilgjengelige sykler ved en gitt bysykkelstasjon én time frem i tid. Pipelinen skal hente inn og behandle tre separate datakilder *stations*, *weather* og *trips* og kombinere dem til et datasett som kan kjøres i maskinlæringsmodeller.

Prosjektet undersøker hvordan ulike maskinlæringsmetoder kan brukes til å modellere mønstre i bysykkeldata og hvordan faktorer som tid, stasjon og vær påvirker sykkeltilgjengeligheten. Arbeidet omfatter dataklargjøring, utforskende analyse, modellutvalg og vurdering av generaliseringsevne. Målet er å bygge en robust og forklarbar modell som kan gi innsikt i etterspørselen etter bysykler over tid.

Del 1 Visualisering og dataklargjøring

Første steg var å undersøke datakvalitet og struktur. Rådata kan inneholde feil, duplikater eller ufullstendige tidsserier, og slike forhold må korrigeres før modellering. For å unngå datalekasje ble datasettet først delt inn i trening-, validering- og testsett.

Datasettet ble sortert med hensyn til stasjon og tidsstempel for å sikre korrekt sekvensiell orden. Den innledende visualiseringen av treningsdelen av dataene avdekket et betydelig hull i starten av stations-filen.



Visualisering av observasjoner på stations

Dette indikerte at lignende hull kunne forekomme i validerings- og testdata.

```
Akvariet                    :  42.5% | Største hull:  127.3t
Høyteknologisenteret        :  67.3% | Største hull:  124.1t
Torgallmenningen            : 107.3% | Største hull:  120.3t
Florida Bybanestopp         :  76.6% | Største hull:  120.3t
Studentboligene             :  68.7% | Største hull:  121.3t
Damsgårdsveien 71           :  90.0% | Største hull:  121.8t
Møllendalsplass             :  86.8% | Største hull:  121.3t
Grieghallen                 :  58.3% | Største hull:  125.3t
Dreggsallmenningen Sør      :  59.7% | Største hull:  120.6t
```

Dekning av observasjoner på stations i validering og testdata

Ser at det finnes dekning, men hull som spenner over lengre periode.

```
Dreggsallmenningen Sør      :  64.9% | Største hull:   46.4t
Høyteknologisenteret        :  66.8% | Største hull:  103.3t
Damsgårdsveien 71           :  92.5% | Største hull:   59.2t
Møllendalsplass             : 105.6% | Største hull:   52.7t
Torgallmenningen            : 107.5% | Største hull:   41.7t
Grieghallen                 :  63.7% | Største hull:   37.8t
Florida Bybanestopp         :  85.3% | Største hull:   34.0t
Akvariet                    :  45.0% | Største hull:   96.5t
Studentboligene             :  80.8% | Største hull:  127.1t
```

Dekning av observasjoner på stations i treningsdata

Sjekker også trening settet sin dekning slik at jeg hvordan jeg skal håndtere det. For å sikre dekning og relevans ble data før september 2024 fjernet fra alle kilder. Ettersom stations filen inneholder variabelen free_bikes, som er selve målvariabelen i prediksjonen, ble den betraktet som den mest sentrale datakilden. Deretter ble stations brukt som hovedtabell, mens weather og trips ble koblet på for å tilføre kontekstuelle og forklarende variabler.

Variabelutvalg og datarensing

Flere variabler ble vurdert som overflødige og fjernet.

- longitude, latitude og skipped_updates ble ekskludert fordi de ikke bidrar meningsfullt til prediksjonen.

- free_spots ble fjernet fordi den er lineært avhengig av free_bikes, og dermed ikke tilfører ny informasjon.

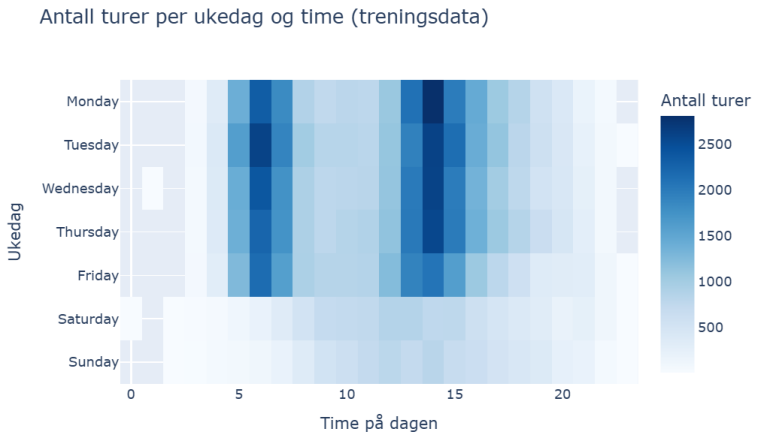
Dataene ble inspisert for hull og duplikater. Enkelte stasjoner viste urealistiske prosentverdier over 100 % dekning, noe som indikerte duplikater. Disse ble fjernet i pipeline-prosessen.

Manglende verdier i weather-data ble fylt ved hjelp av ffill (forward fill) og bfill (backward fill). Denne strategien er hensiktsmessig fordi værforhold endres gradvis, og verdier i nærliggende tids steg er ofte gode estimater. bfill ble inkludert for å håndtere eventuelle NaN-verdier i starten av tidsserien der ffill alene ikke er tilstrekkelig.

Etter delingen viste det seg at treningssettet dekket omtrent fem måneder. Dette innebærer at variabler som måned ikke er egnet som forklaringsvariabel, ettersom modellen ikke får observert alle måneder den skal predikere for. For å unngå overtilpasning mot sesongmønstre ble derfor måned forkastet som variabel.

Utforskende analyser

Analysene viste svak direkte korrelasjon mellom free_bikes og ukedag, men et tydelig mønster i døgnsyklusen: flere ledige sykler om natten. Ved å analysere trips ble det tydelig at sykkelbruken følger arbeidsrytmen, høyest aktivitet i rushtidene og lavere i helgene. Dette motiverte opprettelsen av en ny variabel is_weekend, som et binært uttrykk for helg versus hverdag.



Sammenheng mellom tid og turer startet

I tillegg ble variabelen flow konstruert for å representere samlet trafikkvolum, definert som summen av alle sykkelturer som starter og slutter i Bergen i hver tidsenhet. Denne variabelen skal reflektere total bevegelsesintensitet i Bergen, ikke bare på de stasjonen vi ønsker å predikere på.

Sammenhengen mellom vær og sykkelbruk ble også undersøkt. Direkte korrelasjon mellom free_bikes og værvariabler viste svake mønstre, men en sterkere relasjon mellom temperature og trips_started ble observert.

Resultatene viser at temperatur har en svak positiv sammenheng med free_bikes (corr= 0.342), mens nedbør (−0.002) og vind (−0.026) har minimale eller svakt negative bidrag. Dette tyder på at høyere temperaturer øker aktiviteten noe, mens værforhold som regn og vind har liten praktisk betydning for free_bikes.

Analysen av trips mot vær viser en tydeligere sammenheng: temperatur har en moderat positiv effekt (0.437), mens både nedbør (−0.151) og vind (−0.159) reduserer antall turer. Dette indikerer at varme dager fører til økt sykkelbruk, mens dårlige værforhold generelt demper aktiviteten.

Temperatur antas dermed å være en viktig forklaringsvariabel, mens nedbør og vind har svakere effekt.

Håndtering av manglende data og datakvalitet

Et viktig aspekt i pipeline-utviklingen er håndtering av manglende observasjoner. Ved å undersøke tidsintervallene mellom oppdateringer ble det observert enkelte perioder uten registreringer. For å unngå at interpolering gir feilaktige verdier, ble en terskel på 4 timer innført: dersom et hull i data overstiger 4timer, fjernes raden i stedet for å fylles med LOCF (Last Observation Carried Forward). Dette reduserer risikoen for å introdusere kunstige trender i tidsserien.

Deskriptiv statistikk

Etter sammenslåing og rensing av datasettet ble de numeriske variablene undersøkt med deskriptiv statistikk (tabell 1). Resultatet viser 30 969 observasjoner per variabel. Antallet tilgjengelige sykler free_bikes har et gjennomsnitt på 6,28, men med høy variasjon (standardavvik = 7,15). Dette indikerer store forskjeller mellom stasjoner og tidspunkter. Minimumsverdien på 0 viser at det tidvis ikke finnes ledige sykler, mens maksimum på 34 viser at enkelte stasjoner har høy kapasitet.

	free_bikes	temperature	precipitation	wind_speed	flow
count	30969.000000	30969.000000	30969.000000	30969.000000	30969.000000
mean	6.279021	6.244493	0.363903	11.471417	73.393393
std	7.150705	5.859282	0.775323	7.655663	96.851922
min	0.000000	-12.600000	0.000000	0.000000	0.000000
25%	1.000000	2.700000	0.000000	5.400000	3.000000
50%	3.000000	6.700000	0.000000	9.600000	37.000000
75%	10.000000	9.900000	0.300000	16.200000	106.000000
max	34.000000	27.900000	6.800000	40.600000	556.000000

Deskriptiv statistikk av variabler fra model_ready.csv

Temperatur varierer fra −12,6 °C til 27,9 °C, med et gjennomsnitt på 6,24 °C. Dette bekrefter at dataperioden omfatter både vinter og sommermåneder. Nedbør har et gjennomsnitt på 0,36 mm, men en tydelig høyreskjev fordeling, de fleste perioder har lite eller ingen nedbør, men enkelte episoder har opptil 6,8 mm. Vindhastighet har et gjennomsnitt på 11,47 m/s, med maksimum 40,6 m/s, noe som tyder på enkelte ekstremverdier som mulig påvirker sykkelbruken.

Variabelen flow, som beskriver samlet antall turer startet og avsluttet i Bergen per tidsenhet, har et gjennomsnitt på 73 og høy standardavvik (≈ 96,9). Spennet fra 0 til 556 viser store svingninger i aktivitetsnivået gjennom døgnet og mellom ukedager.

Tabellen viser dermed at datagrunnlaget dekker brede variasjoner i både værforhold og sykkelbruk, noe som er gunstig for modellens evne til å generalisere.

Del 2 Modellutvalg:

Målet med denne delen av prosjektet er å identifisere den mest egnede regresjonsmodellen for å predikere antall tilgjengelige bysykler én time frem i tid. Arbeidet bygger videre på den etablerte datapipelinen utviklet i del 1, som transformerer rådata fra stations, weather og trips til et modellklart datasett. Fokus i denne fasen er systematisk modellutvelgelse, tuning av hyperparametere og til slutt vurdering av generaliseringsevne.

Datagrunnlag og deling

Datasettet blir generert av pipelinen vi lagde i del 1. Dette sikrer konsistent forbehandling, inkludert rydding av manglende verdier, fjerning av duplikater og sammenslåing av informasjon fra de tre datakildene. Etter generering ble målvariabelen identifisert som free_bikes, og kolonnene timestamp og station ble ekskludert fordi modellen vi bruker bare kan håndtere numeriske verdier.

Datasettet ble delt i 60/20/20 ved hjelp av train_test_split uten stokking, for å bevare tidsrekkefølgen. Alle modellene ble tunet med GridSearchCV og TimeSeriesSplit, noe som sikrer at validering følger tidsrekkefølgen i dataene. Denne metoden er spesielt viktig for tidsserier, fordi standard krysvalidering med tilfeldig splitting ville føre til datalekasje mellom fremtid og fortid.

Baseline-modell

Analysen startet med en baseline-modell Dummyregressor og etter å ha kjørt noen av modellen så jeg at det var veldig stort forskjell. Dummyregressor hadde ca. 8 i RMSE. Det gjorde at jeg ønsket en annen baseline. Etter å ha lest i discorden så jeg et forslag om at baseline prediksjon kan være å bare predikere hva free_bikes er på tidspunktet man predikerer for. Ettersom free_bikes ikke endrer seg dramatisk fra time til time så jeg for

meg at den kunne funke greit, men den presterte overaskende bra. Baseline fikk 1.824 i RMSE på testdata. Noe jeg anser som bra når standardavviket på free_bikes er ca. 7.

Modellkandidater og hyperparameter-tuning

Tre hovedmodeller ble valgt for sammenligning. Alle ble innkapslet i Pipeline-objekter og tunet med GridSearchCV i kombinasjon med TimeSeriesSplit(n_splits=5) og negativ MSE som evalueringsmetrikk siden modellene alltid prøver å maksimere score. Hver modell ble trent og validert på fem sekvensielle fold. Gjennomsnittlig RMSE fra kryssvalidering ble brukt til å sammenligne ytelse.

Etter å ha sett på forskjellige modeller fra SkLearn, endte jeg opp med HGB, Ridge og KNN. Disse representerer tre fundamentalt forskjellige tilnærminger til regresjonsproblemet og dekker både lineære og ikke-lineære relasjonsmønstre i datasettet. Formålet med å teste ulike modellarkitekturer er å finne en balanse mellom forklaringskraft, generaliseringsevne og robusthet mot støy i tidsseriedata.

1. **HistGradientBoostingRegressor**

HistGradientBoostingRegressor er en ensemblemodell som bygger opp et sett med beslutningstrær sekvensielt, der hvert nytt tre prøver å korrigere feilene fra forrige. Denne modellen egner seg godt til oppgaven fordi datasettet består av komplekse og ikke-lineære relasjoner mellom tid, stasjon, vær og sykkelbruk. Metoden kan håndtere både kontinuerlige og kategoriske variabler og er robust mot skjevfordeling og manglende lineære sammenhenger.

Hyperparameterne ble valgt for å kontrollere modellens læringsdynamikk og kompleksitet:

- **learning_rate** ∈ [0.03, 0.05, 0.1]: styrer hvor mye hvert enkelt tre bidrar til den endelige prediksjonen. Små verdier gir stabil, men treg læring; høyere verdier gir raskere læring, men risiko for overtilpasning.

- **max_depth** ∈ {None, 6, 12}: begrenser dybden på trærne for å balansere modellens fleksibilitet mot risikoen for overfitting.
- **min_samples_leaf** ∈ {20, 50}: hindrer modellen i å lage for små løv, noe som reduserer sensitivitet for støy i data.
- **l2_regularization** ∈ {0.0, 0.1}: bidrar til å straffe store koeffisienter og stabiliserer modellen ved å redusere varians.

Denne kombinasjonen gjør modellen godt egnet til tidsseriedata med både jevne og brå endringer i mønstre, som ved sykkelbruk påvirket av vær, klokkeslett og ukedag.

2. **Ridge Regression**

Ridge er en lineær modell med L2-regulering. Den er inkludert for å teste hvorvidt sammenhengen mellom variablene kan beskrives lineært, samtidig som reguleringen begrenser effekten av multikollinearitet. Dette er særlig nyttig i denne konteksten der enkelte vær- og tidsvariabler kan være korrelert.

Parameteren alpha ble søkt i logaritmisk skala (10^{-2} til 10^{2}) for å finne riktig balanse mellom bias og varians. En lav alpha tillater modellen å tilpasse seg data mer fleksibelt, mens en høy verdi øker regulariseringen og reduserer overtilpasning.

Selv om Ridge ikke fanger opp ikke-lineære effekter, fungerer den som et viktig referansepunkt for å vurdere verdien av mer komplekse modeller.

3. **KNeighborsRegressor**

KNeighborsRegressor er en ikke-parametrisk metode som estimerer verdier basert på gjennomsnittet av nærmeste naboer i treningsdata. Denne modellen er nyttig når man forventer lokale mønstre i datasettet, for eksempel at antall tilgjengelige sykler ved en gitt stasjon til et gitt tidspunkt ligner tidligere observasjoner på omtrent samme tid og ukedag.

Parameterne ble valgt for å teste hvordan antall naboer og vekting påvirker ytelsen:

- **n_neighbors** ∈ {3, 5, 10, 20}: kontrollerer hvor mange observasjoner som brukes til å beregne prediksjonen. Få naboer gir høy varians; mange naboer gir høy bias.
- **weights** ∈ {"uniform", "distance"}: avgjør om alle naboer skal vektlegges likt, eller om nærmeste observasjoner skal tillegges større betydning.

Denne modellen krever skalering av data (StandardScaler) for å sikre at alle trekk påvirker avstandsberegningen likt.

Variabelutvalg

	feature	delta_MSE	std
9	free_bikes	14.916068	0.204777
14	hour	0.398113	0.034359
13	flow	0.174685	0.008577
3	station_Høyteknologisenteret	0.164255	0.010647
8	station_Florida Bybanestopp	0.048188	0.003447
5	station_Akvariet	0.020293	0.005132
0	station_Møllendalsplass	0.014376	0.004246
6	station_Damsgårdsveien 71	0.014298	0.002407
1	station_Torgallmenningen	0.012468	0.002722
4	station_Studentboligene	0.011378	0.001977
10	temperature	0.004936	0.004331
2	station_Grieghallen	0.003284	0.001658
15	is_weekend	0.001123	0.000512
11	precipitation	0.000373	0.001011
7	station_Dreggsallmenningen Sør	-0.000652	0.000700
12	wind_speed	-0.001233	0.003023

Etter å ha funnet den beste modellen prøvde jeg å finne de mest forklarende variablene gjennom permutation_importance fra SkLearn. Tabellen viser resultatene fra permutation Importance, som måler hvor mye modellens prediksjonsfeil (ΔMSE) øker når hver enkelt variabel stokkes. Jo høyere verdi, desto viktigere er variabelen for modellens ytelse.

Resultatene viser at free_bikes er den klart viktigste forklaringsvariabelen. Dette er forventet, siden den beskriver det historiske nivået av tilgjengelige sykler som modellen forsøker å forutsi. Deretter følger hour og flow, som indikerer at både tidspunkt på døgnet og samlet trafikkvolum har betydelig innflytelse på tilgjengeligheten.

Flere stasjonsvariabler, som Høyteknologisenteret og Florida Bybanestopp, har også relativt høye bidrag, noe som tyder på at lokal variasjon mellom stasjoner spiller en rolle. Værrelaterte variabler som temperature, precipitation og wind_speed har svært lav ΔMSE, og enkelte (for eksempel wind_speed) gir til og med negativ effekt, noe som tyder på at de ikke bidrar til prediksjonsevnen for denne modellen.

Samlet viser analysen at modellen i hovedsak baserer seg på tidsmessige og stasjonsavhengige mønstre, mens værforhold har liten prediktiv verdi i denne datastrukturen.

Ettersom alle variablene viste positivt bidrag til modellens prediksjonsevne, ble det ikke ansett som nødvendig å redusere datasettet ytterligere. For å undersøke effekten av variabelreduksjon ble det likevel gjort et testforsøk der kun de tre mest betydningsfulle variablene free_bikes, hour og flow ble brukt som input. Den beste modellen ble deretter tilpasset på treningsdata og evaluert på valideringsdata. Resultatet viste en marginal økning i RMSE (mindre enn 0.1), noe som indikerer at de øvrige variablene bidrar lite til presisjonen, men at de heller ikke skaper overtilpasning.

Dette støtter at den opprinnelige modellen har en hensiktsmessig balanse mellom kompleksitet og generaliseringsevne.

Konklusjon

Etter en lærerik og omfattende prosess oppnådde den endelige modellen en generaliseringsfeil på 1.80 RMSE. Det betyr at modellen i gjennomsnitt bommer med omtrent 1,8 sykler per prediksjon, kun en marginal forbedring sammenlignet med baseline-modellen (1.824 RMSE). Resultatet antyder at datagrunnlaget er begrenset i både varighet og sesongmessig bredde. Treningssettet omfattet kun fem måneder, slik at modellen ikke fikk mulighet til å lære sesongmønstre som påvirker sykkelbruk sterkt.

Den beste modellen, en HistGradientBoostingRegressor, oppnådde et gjennomsnittlig RMSE på 1.59 under 5-fold tidsserie-kryssvalidering og 1.11 ved validering på hold-out valideringsdata. Ved endelig evaluering på testdata steg feilen til 1.81, noe som tyder på redusert ytelse utenfor den tidsperioden modellen ble trent på. Dette bekrefter at tilgjengeligheten av bysykler er sterkt sesongavhengig og at modellen ville dratt nytte av et lengre og mer variert datagrunnlag

Bruk av kunstig intelligens (KI)

Kategori E – KI som støtte til programmering

Tjenesten *ChatGPT (OpenAI, GPT-5)* ble brukt til feilsøking og forbedring av Python-kode knyttet til modellutvalg, GridSearchCV, og TimeSeriesSplit.

Ledetekst:

"Forklar hvorfor denne koden feiler, og hvordan jeg kan forbedre den uten datalekasje."

KI-verktøyet ble brukt til teknisk veiledning og optimalisering, men all implementasjon, testing og fortolkning av resultater er gjort av meg.

Kilder

Blasern, B. 2023. Data Science – Forelesningsnotater. *blasern.github.io.* [Internett] 2023. https://blasern.github.io/data-science-forelesningsnotater/intro.html.

Pedregosa, F., et al. Scikit-learn: Machine Learning in Python (Documentation). *scikit-learn.org.* [Internett] https://scikit-learn.org/stable/api/index.html.